

Guía Didáctica: Fase 3 - Preparación de los Datos (CRISP-DM)

Esta fase es crucial: aquí es donde invertimos el 80% de nuestro tiempo para asegurar que la calidad de los datos sea óptima. Trabajaremos en la limpieza, construcción de nuevas variables y formateo técnico.

1. Librerías Necesarias

Para esta etapa, utilizaremos el ecosistema estándar de Ciencia de Datos en Python:

```
import pandas as pd    # Manipulación de dataframes
import numpy as np     # Operaciones numéricas y manejo de NaNs
import re              # Expresiones regulares para limpieza de texto
```

2. Actividades y Código Python

A. Limpieza de Datos (Data Cleaning), nuestra prioridad es corregir la columna `user_review`, que actualmente es de tipo texto debido a los valores "tbd".

```
# Cargar el dataset

df = pd.read_csv('all_games.csv')

# 1. Convertir 'user_review' a numérico, transformando 'tbd' en NaN
# (Not a Number)

df['user_review'] = pd.to_numeric(df['user_review'], errors='coerce')

# 2. Manejo de valores nulos
# Decisión: Llenar nulos en 'summary' con "No description available"

df['summary'] = df['summary'].fillna("No description available")

# Eliminar filas donde 'user_review' es NaN si nuestro objetivo es
# comparar scores

df_clean = df.dropna(subset=['user_review']).copy()
```

B. Construcción de Atributos (Feature Engineering), creamos nuevas variables que aporten valor al análisis de negocio.

```
# 1. Extraer el Año de lanzamiento de la columna 'release_date'

df_clean['release_year'] =
pd.to_datetime(df_clean['release_date']).dt.year

# 2. Crear la "Brecha de Percepción" (Diferencia entre Crítica y
# Usuarios)
# Nota: Escalamos user_review (0-10) a la misma escala que meta_score
# (0-100)

df_clean['score_diff'] = df_clean['meta_score'] -
(df_clean['user_review'] * 10)
```

C. Integración y Formateo, aseguramos que el dataset sea consistente y fácil de procesar.

```
# 1. Eliminar espacios en blanco innecesarios en nombres de columnas y textos
```

```
df_clean['name'] = df_clean['name'].str.strip()
```

```
# 2. Selección de columnas finales para el modelado
```

```
df_final = df_clean[['name', 'platform', 'release_year', 'meta_score', 'user_review', 'score_diff']]
```

```
print("Dataset preparado. Filas restantes:", len(df_final))
```

3. Checkpoint de Calidad (Validación Técnica), ejecuta este bloque de código para confirmar que el dataframe `df_final` cumple con los requisitos de la fase de preparación:

```
# 1. Validación de tipos de datos
```

```
check_types = df_final['user_review'].dtype == 'float64'  
print(f"¿Columna 'user_review' es float64?: {check_types}")
```

```
# 2. Validación de valores nulos
```

```
null_count = df_final.isnull().sum().sum()  
print(f"¿Valores nulos totales en el set final?: {null_count}")
```

```
# 3. Validación de formato temporal
```

```
check_year = 'release_year' in df_final.columns and  
df_final['release_year'].dtype == 'int64'  
print(f"¿Variable temporal 'release_year' lista?: {check_year}")
```

```
# 4. Vista previa de la consistencia (Primeras 5 filas)
```

```
print("\n--- Verificación de Consistencia de Datos ---")  
print(df_final[['name', 'meta_score', 'user_review', 'score_diff']].head())
```